


## EMP 전략

### 강화학습을 활용한 투자 전략



▶ EMP 전략 권병재 | [byeongjae.kwon@hanwha.com](mailto:byeongjae.kwon@hanwha.com) | 3772-7624

“

강화학습은 기계 학습의 한 영역으로, 모델이 시행착오를 통해 행동을 학습하는 과정입니다. 본 알고리즘은 국내 증시, 가상화폐 시장에서 롱과 숏이라는 선택지를 갖고 매 거래일 비중을 조정하며 절대 수익률을 추구합니다.

”

## | Contents |

---

I. 핵심 요약 .....	03
II. 들어가며 .....	04
III. 알고리즘 이론 배경 .....	05
강화학습 .....	05
Q 러닝 .....	06
함수 근사 .....	07
경사 하강 .....	08
IV. 국내 증시로의 적용 .....	09
거래비용 고려 .....	10
성과 .....	12
V. 가상화폐 시장으로의 적용 .....	13
Funding Fee .....	13
성과 .....	14
테스트 기간 변경 .....	15
VI. 결론 .....	16

## I. 핵심 요약

2022년 11월 Open AI가 Chat GPT를 출시하면서 전세계적인 AI 붐이 시작됐다. 먼 미래로 여겨졌던 AI 기술이 대중에게 다가오자 다수의 국가와 기업이 AI 산업에 뛰어들고 있다.


AI의 주요 분야 중 하나인 기계 학습(Machine Learning)은 크게 지도학습과 비지도학습, 그리고 강화학습으로 나뉜다. 본 자료는 강화학습을 활용한 포트폴리오 알고리즘을 소개한다. 모델은 룡과 섯이라는 섯택자를 갖고 매 거래일 비중을 조정하며 절대 수익률을 추구한다. 비중을 조정할 때에는 가능한 섯택지 중 기대수익률이 가장 높은 행동을 취한다.

본 알고리즘은 1) 국내 주식(ETF) 시장과 2) 가상화폐 시장을 대상으로 한다. 국내 주식(ETF) 시장에서는 현금, KOSPI200 ETF(Long or Short), KOSDAQ150 ETF(Long or Short)에, 가상화폐 시장에서는 현금, BTCUSDT(Long or Short), ETHUSDT(Long or short)에 각각 베텡한다.

국내 주식(ETF) 시장에 현 모델을 적용하기는 어려워보인다. 모델의 성과가 거래 비용(0.2% 설정)을 이기지 못했다. 모델 수익률이 학습 진행에 따라 일정한 방향을 보이지 않았다는 점에서도 기계 학습이 잘 이루어졌다고 판단하기 어렵다.

가상화폐 시장에서의 성과는 괄목할 만하다. 전체적인 수익률은 부진했지만, 여러 테스트 기간에서 유사한 수익률 패턴을 보였다. 이는 결과에 대한 신뢰를 높여준다. 학습률을 낮추어 모델 학습의 안정성을 높이는 등의 방법으로 모델을 개선할 필요가 있다.

[그림1] 알고리즘 구조도



## II. 들어가며

2022년 11월 Open AI가 Chat GPT를 출시하면서 전세계적인 AI 붐이 시작됐다. 먼 미래로 여겨졌던 AI 기술이 대중에게 다가오자 다수의 국가와 기업이 AI 산업에 뛰어들고 있다. AI 기술이 대중에게 충격을 안겨줬던 것은 비단 처음이 아니다. 2016년 3월 구글 딥마인드의 알파고는 이세돌 구단과의 대국에서 4:1로 승리했다.

AI의 주요 분야 중 하나인 기계 학습(Machine Learning)은 크게 지도학습과 비지도학습, 그리고 강화학습으로 나뉜다. 지도학습/비지도학습은 데이터를 학습하고 규칙을 찾는 것에 목적을 둔다. 널리 알려진 선형회귀가 여기에 속한다. 입력과 결과가 주어진 데이터에서 규칙을 찾고, 이후 새로운 입력이 주어졌을 때 그에 대한 결과를 예측한다.

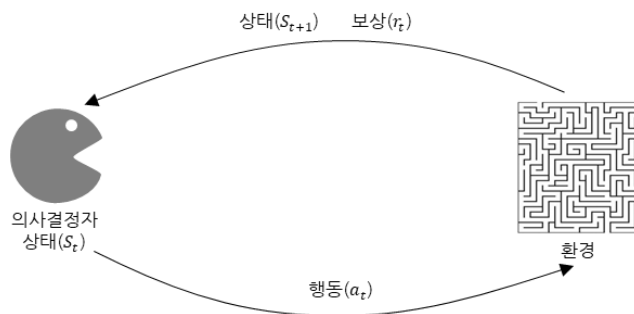
강화학습은 보다 동적이다. 주어진 데이터에서 어떤 행동을 취할 지에 중점을 둔다. 행동은 보상(Reward)으로 이어지고, 보상의 크고 작음이 모델 학습에 영향을 미친다. 이러한 특성 덕분에 강화학습은 게임 분야에서 놀라운 성능을 보였고, 2013년 구글 딥마인드는 Atari 비디오게임 플레이를 스스로 터득하는 DQN(Deep Q-Network)을 개발했다.

본 자료는 강화학습을 활용한 포트폴리오 알고리즘을 소개한다. 게임과 투자는 크게 다르지 않다. 플레이어가 승리를 위해 주어진 상황에서 최적의 선택을 하고자 노력하듯, 투자자는 금융시장에서 수익을 위해 최적의 행동을 선택하기 때문이다. 소개할 알고리즘은 룬과 숫이라는 선택지를 갖고 매 거래일 비중을 조정하며 절대 수익률을 추구한다. 비중 조정을 위해 수익률의 기대값을 추정하는데, 이때 딥마인드가 제시했던 DQN을 활용했다.

### III. 알고리즘 이론 배경

#### 강화학습


시행착오는 인간의 학습 방법 중 하나다. 행동을 취했을 때 벌어지는 결과로 인과관계를 추론한다. 결과가 좋다면 유사한 상황에서 동일한 행동을 취할 것이다. 강화학습은 같은 과정을 모델에 적용한다. 알고리즘의 의사결정자(Agent)가 주어진 상태(State)에서 행동(Action)을 취하면, 환경은 의사결정자에게 다음 상태와 보상(Reward)을 반환한다. 보상이 좋다면 향후 유사한 상태에서 모델은 같은 행동을 취할 것이다.



강화학습을 투자 알고리즘에 적용하기 위해서는 **상태**와 **행동**, **보상**을 금융시장에 알맞도록 정의해야 한다. “A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem”(Zhengyao Jiang 외 2명, 2017)에서 저자는 알고리즘의 **상태**를 1) 자산별 가격(종가, 저가, 고가), 2) 현재 자산 비중으로 봤다. 기술적 관점에서 금융시장 내 많은 정보가 가격에 내포돼 있기 때문에 1) 자산별 가격은 현재 금융 시장을 의미한다. 거래 비용이 모델에 고려된다면, 자산 비중을 조정할 때에는 2) 현재 자산 비중을 알아야 한다.

**행동**은 다음 거래를 위한 자산 비중으로 정의했다. **보상**은 포트폴리오 수익률이다.

[그림2] 강화학습을 투자 알고리즘에 적용



자료: “A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem”, 한화투자증권 리서치센터

## Q 러닝

게임이든 투자든 기대값이 높은 행동을 선택한다면 승리에 다가갈 수 있다. Q러닝은 특정 행동을 취했을 때의 기대 보상을 학습하는 과정이다.  $t$  시점 행동으로 얻어지는 보상을  $r_t$ 이라고 하면, 거래 기간 총 보상은 다음과 같다.

$$G = r_0 + r_1 + r_2 + \dots + r_{T-1} = \sum_{t=0}^{T-1} r_t$$

장기 보상에는 감가율을 곱하는 것이 일반적이나(금융 시장에 적용하면 무위험수익률로 할인) 본 알고리즘에서는 감가율을 적용하지 않았다. 편의를 위해 앞으로 등장할 수식에서도 감가율은 제외하겠다.

특정 상태와 행동에 대해 가치를 평가하는 행동-가치함수(Action-Value Function)는 얻게 될 보상들의 기대값이다.

$$Q_{\pi}(s, a) = E_{\pi}[G | s_0 = s, a_0 = a]$$

위에서 정의했던 전체 기간에 대한 보상  $G$ 와 행동-가치함수  $Q_{\pi}(s, a)$ 를 특정 시점  $t$ 에 대해 다음과 같이 재귀적으로 표현할 수 있다.

$$G_t = r_t + (r_{t+1} + r_{t+2} + \dots + r_{T-1}) = r_t + G_{t+1}$$

$$\begin{aligned} Q_{\pi}(s, a) &= E_{\pi}[G_t | s_t = s, a_t = a] \\ &= E_{\pi}[r_t + G_{t+1} | s_t = s, a_t = a] \\ &= E_{\pi}[r_t + Q_{\pi}(S_{t+1}, a_{t+1}) | s_t = s, a_t = a] \end{aligned}$$

Q 러닝은  $t$  시점의 행동-가치함수를  $t$  시점 보상과  $t+1$  시점의 행동-가치함수로 업데이트하는 과정이다.

$$Q_{\pi}(s_t, a_t) \leftarrow Q_{\pi}(s_t, a_t) + \alpha[r_t + Q_{\pi}(S_{t+1}, a_{t+1}) - Q_{\pi}(s_t, a_t)]$$

$\alpha$ : 학습률

## 함수 근사

Q 러닝을 통해 상태, 행동마다 향후 보상에 대한 기대값을 테이블 형태로 저장할 수 있다. 상태, 행동의 가지수가 적다면 좋은 방법이지만, 경우의 수가 많거나 무한하게 되면 Q 러닝이 불가능하다.


해결책 중 하나는 함수 근사기(function approximator)를 사용하는 것이다. 상태와 행동에 따라 데이터를 모두 저장하지 않고 상태와 행동을 기대값에 대응하는 계수를 저장한다. 선형 회귀로 예를 들면 100개의 순서쌍  $(x, y)$  데이터를 모두 저장하지 않고, 데이터를 잘 설명하는 직선의 계수(기울기, y절편)만 저장하고 업데이트한다.

$$Q(s, a; \theta) \approx Q(s, a)$$

함수 근사기로는 선형(Linear)부터 신경망(Neural Network)같은 비선형 근사기가 사용되기도 한다. 본 알고리즘에서는 CNN(합성곱 신경망, Convolution Neural Network)을 사용했다. CNN은 일반적으로 이미지 인식에 주로 사용되는데, R, G, B 3개 채널을 갖는 2차원 이미지는 종가, 고가, 저가, (시가) 채널을 갖는  $m \times n$  데이터( $m$ 개 자산  $n$ 거래일 데이터)와 유사하다.

본 알고리즘은 “Application of Deep Q-Network in Portfolio Management”(Ziming Gao 외 4명, 2020)에서 사용된 신경망을 일부 조정하여 사용했다. CNN은 이미지로부터 데이터를 추출하고 분류한다. 추출 과정은 3개의 convolution layer로 구성되고, 분류는 1개의 fully connected layer로 구성돼 있다.

[그림3] 이미지 인식에 주로 사용되는 CNN(합성곱 신경망)



자료: 한화투자증권 리서치센터



## 경사 하강

Q 러닝에서는 행동-가치함수가 상태, 행동에 따라 업데이트되도록 학습이 진행됐다면, 여기서는 함수 근사기가 목표하는 행동-가치함수와 유사하도록 학습이 이뤄진다. 이를 손실함수(Loss Function)로 표현하면 다음과 같다. 학습은 손실함수를 최소로 하는 방향으로 진행된다.

$$L_i(\theta_i) = E_{s,a} [(y_i - Q(s, a; \theta_i))^2]$$

$$s. t. \quad y_i = r_t + \max_{a'} Q(s_{t+1}, a'; \theta_{i-1})$$


손실함수를 최소로 하도록 학습을 진행하기 위해 주로 경사 하강(Gradient Descent)이 사용된다. 함수가 미분가능하다면 최소값을 찾기 위해 일반적으로 1차 도함수가 0이 되는 지점을 찾지만, 현실에서 마주하는 함수의 대부분은 도함수를 도출하기 어렵다. 경사 하강법은 함수가 최소가 되는 지점을 찾기 위해 시작점으로부터 여러 반복을 통해 도착점 근처까지 도달한다. 도착점으로 가는 방향은 함수의 그래디언트(편미분 벡터)다. 본 알고리즘에서는 경사하강의 응용인 ADAM(Adaptive Moment Estimation)을 사용했다.

$$\theta = \theta - \alpha \nabla_{\theta} L(\theta)$$

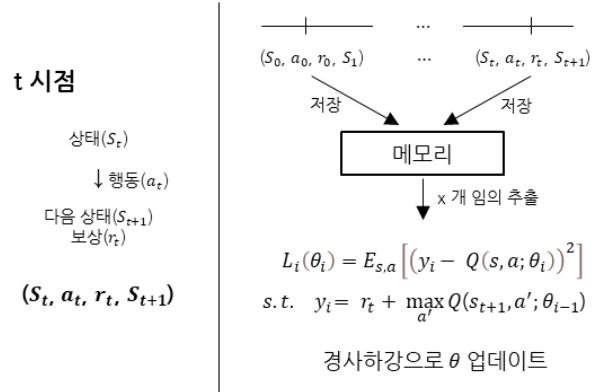
$\alpha$ : 학습률

“Playing Atari with Deep Reinforcement Learning”(Volodymyr Mnih 외 6명, 2013)에서 딥마인드는 연속된 데이터를 사용하지 않고 메모리에 데이터를 저장한 후 일부를 임의 추출하여 경사하강을 사용했다. 메모리 저장, 추출 시 데이터 효율성과 데이터 간 상관성 감소를 얻을 수 있다.

[그림4] 경사하강(Gradient Descent)



[그림5] 메모리에서 임의 추출하여 데이터 간 상관성 감소





## IV. 국내 증시로의 적용

알고리즘의 투자 대상은 다음과 같다.

- 1) 현금: (무위험)수익률은 0으로 가정
- 2) KOSPI200: Long(KODEX 200) or Short(KODEX 인버스)
- 3) KOSDAQ150: Long(KODEX 코스닥150) or Short(KODEX 코스닥150선물인버스)

상태(State): 1) KOSPI200, KOSDAQ150 지수의 최근 10거래일 종가, 시가, 고가, 저가를 최근 1거래일 종가로 정규화한 데이터, 2) 현재 자산 비중(각 자산별 비중 절대값의 합은 100%)


행동(Action): 다음 거래일을 위한 자산 비중(10% 단위)

보상(Reward): 포트폴리오 일일 로그수익률

지수의 상승, 하락이 고루 분포되어 있는지를 고려하여 학습, 테스트 기간을 다음과 같이 선정했다.


- 1) 학습 기간: 2016년 12월 29일 ~ 2018년 12월 28일
- 2) 테스트 기간: 2022년 1월 3일 ~ 2023년 12월 28일

[그림6] 학습 기간 KOSPI200, KOSDAQ150 추이



자료: 한화투자증권 리서치센터

[그림7] 테스트 기간 KOSPI200, KOSDAQ150 추이



자료: 한화투자증권 리서치센터

## 거래비용 고려

알고리즘은 테스트 기간 동안 거래일마다 종가 기준으로 투자 대상의 비중을 조정한다. 매매 시 발생하는 거래 비용은 0.20%로 설정했다. ETF 거래 비용으로는 매매 시 발생하는 증권사 수수료와 ETF 호가에 반영되는 헤지비용을 고려했다. 분배금과 세금은 고려하지 않았다. KODEX 200과 KODEX 코스닥150은 국내 주식형 ETF로 과세가 없고, KODEX 인버스와 KODEX 코스닥150선물인버스는 과표증분이 적어 과세가 미미하기 때문이다.

거래비용이 모델에 반영된다면 비중 조정 시에도 이를 반영하는 장치가 필요하다. 예를 들어 주식 60%, 현금 40%인 포트폴리오를 주식 70%, 현금 30%인 포트폴리오로 조정한다고 하면, 비용을 고려하지 않으면 전체 자산의 10%만큼 주식을 매수하면 된다.

거래 비용 X	변경 전	비중 조정	비용	변경 후
현금	40%	-10%	0%	30%
주식	60%	+10%	0%	70%

거래비용을 고려한다면 계산이 복잡해진다. 주식은 70%로 동일하지만 현금 비중이  $40\% - 10\% - 0.02\% = 29.98\%$ 로 30%에 못 미치기 때문이다.

거래 비용 O	변경 전	비중 조정	비용	변경 후
현금	40%	-10%	0.02%	29.98%
주식	60%	+10%	0%	70%

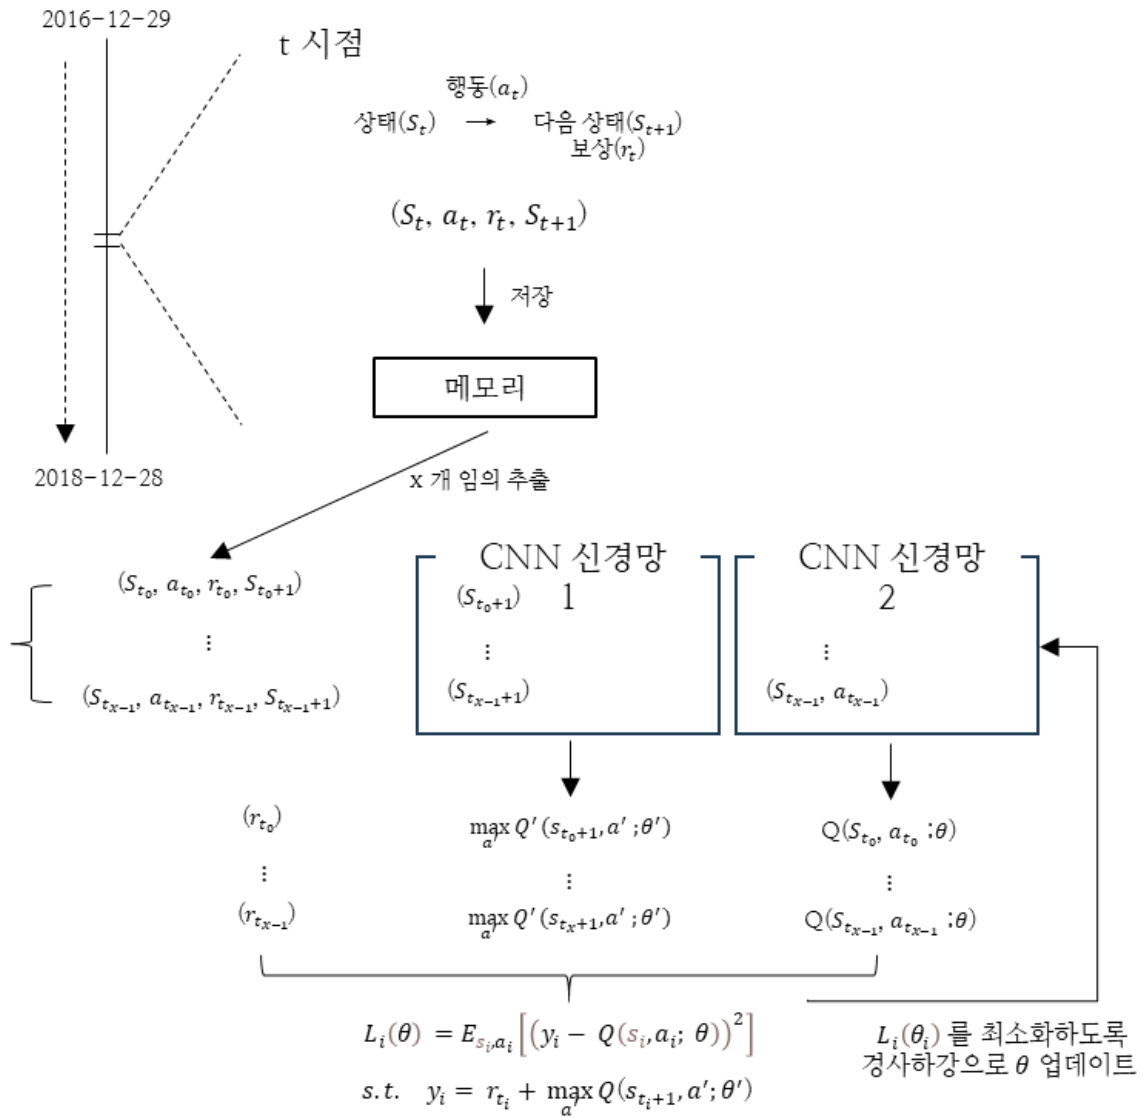
따라서 비중 조정 시 거래비용을 감안한다면 교정이 필요하고, 본 알고리즘에서는 비중 조정 행렬을 만들어 사용했다.

$$\begin{pmatrix} 1 & 0.00139804 \\ 0 & 0.99860196 \end{pmatrix} \begin{pmatrix} -0.1 \\ +0.1 \end{pmatrix} = \begin{pmatrix} -0.09986196 \\ +0.09986196 \end{pmatrix}$$

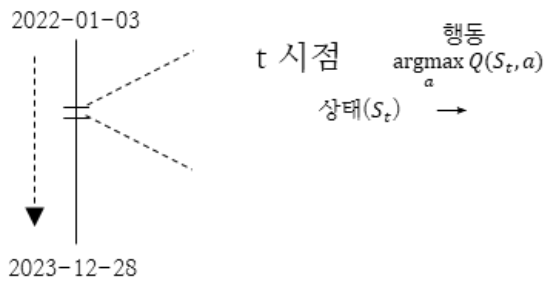
주식을 10%가 아닌 9.98602% 매수하면 거래비용이 현금에서 차감됐을 때 주식과 현금의 비율이 7:3으로 조정된다. 위 행렬은 예시이며 비중마다 다르게 적용됐다.

## 학습 1회 사이클(epoch)

### 학습



### 테스트(학습 100회마다)




## 성과

기계 학습에서 성과를 확인하는 주요 방법 중 하나는 ‘학습이 진행됨에 따라 결과가 좋아지는지’ 확인하는 것이다. [그림8]은 100회 학습 사이클(epoch)마다 포트폴리오의 수익률을 보여준다. 총 10,000회 학습 사이클(epoch)에서 알고리즘의 수익률은 대부분 부진했으며 학습이 진행되도 수익률은 나아지지 않았다.

모델이 부진했던 이유는 매 거래일 발생하는 0.2% 거래 비용을 감당할 수 없었기 때문이다[그림10]. ETF를 매매하면서 거래 손익은 항상 양수였지만 잦은 거래에 따른 비용을 이길 수 없었다. 학습 진행 시 수익률이 개선되지 않았다는 점도 모델의 수익성을 의심하게 만드는 요인이다.


알고리즘의 매매 빈도를 줄이기 위해 모델 학습 시 수익률에 거래 비용을 반영했으나, 기대와 달리 학습이 진행되도 거래 비용은 줄지 않았다. 100번의 테스트에서 평균 거래 비용은 2년 동안 총 자산의 67%에 달했다. 연으로 환산하면 총 자산의 약 34%였다.

[그림8] 테스트 기간(2 년) 알고리즘 수익률 추이




자료: 한화투자증권 리서치센터

[그림9] 테스트 기간(2 년) 총 자산 대비 거래비용



자료: 한화투자증권 리서치센터

[그림10] 수익률 분해



자료: 한화투자증권 리서치센터

## V. 가상화폐 시장으로의 적용

### Funding Fee

기업 손익과 매크로 지표 등에 영향받는 주식 시장과 달리, 가상화폐 시장에는 가격에 영향을 미치는 요인이 적다. 휴장이 없어 시계열이 연속성을 갖기 때문에 알고리즘 적용이 용이하다.

투자 대상은 아래와 같다. 매매 방식은 국내 증시와 동일하다.

1. 현금: (무위험)수익률은 0으로 가정
2. BTCUSDT: Long or Short(레버리지 비율은 Long, Short 모두 1배율)
3. ETHUSDT: Long or Short(레버리지 비율은 Long, Short 모두 1배율)


학습, 테스트 기간은 다음과 같다.

- 1) 학습 기간: 2018년 6월 30일 ~ 2020년 6월 30일
- 2) 테스트 기간: 2022년 1월 1일 ~ 2023년 12월 31일

가상화폐 선물 거래에는 거래 비용 외에도 Funding Fee가 있다. 전통 선물 계약의 가치를 보증하는 것은 만기일에 실물 인도 혹은 현금 결제를 이행하는 의무다. 반면 가상화폐 선물의 대부분은 만기가 없어서(Perpetual) 선물의 가치가 현물에 수렴하도록 하는 장치가 필요하다. Funding Fee는 선물 가격이 현물보다 높을 때 매수자가 매도자에게 일정 비율의 금액을 지불하고, 반대의 경우는 매도자가 매수자에게 지불한다.


$$\text{선물 거래 수익} = \text{선물 가격 변화} + \text{Funding Fee} - \text{거래 비용}$$

[그림11] 학습 기간 BTCUSDT(현물), ETHUSDT(현물) 추이



자료: Binance, 한화투자증권 리서치센터

[그림12] 테스트 기간 BTCUSDT, ETHUSDT 추이




자료: Binance, 한화투자증권 리서치센터

## 성과

매매 시 지불하는 거래비용과 달리 Funding Fee는 포지션에 따라 일정 금액을 지불할 수도, 받을 수도 있기 때문에 Funding Fee가 수익률에 미치는 영향은 미미하다[그림15]. 모델 학습 시에는 Funding Fee를 고려하지 않았고 테스트 결과에만 반영했다.


[그림13]은 100회 학습 사이클(epoch)마다 포트폴리오의 수익률을 보여준다. 총 10,000회 학습 사이클에서 알고리즘의 수익률은 대부분 부진했으나 국내 증시와 달리 학습 진행에 따라 방향성을 보였다. 100~2,000회 학습까지는 포트폴리오 수익률이 양호했지만, 이후 학습에서 부진한 모습을 보였다. 거래 비용은 수익률과 반대 방향을 보였다.

[그림13] 테스트 기간(2년) 알고리즘 수익률 추이




자료: Binance, 한화투자증권 리서치센터

[그림14] 테스트 기간(2년) 총 자산 대비 거래비용



자료: Binance, 한화투자증권 리서치센터

[그림15] 수익률 분해



자료: Binance, 한화투자증권 리서치센터

## 테스트 기간 변경


앞의 결과가 나올 수 있는 경우 중 단지 하나일지(우연), 학습 진행에 따라 수익률의 방향이 존재했던 것인지 알아볼 필요가 있다.

[그림16, 17]은 테스트 기간을 기존 2022 ~ 2023년에서 각각 2021년, 2023년 1월로 변경했을 때의 수익률이다. 학습된 알고리즘의 변수는 기존과 동일하다(즉, 주어진 최근 10거래일 데이터와 현재 자산 비중으로 다음 비중을 출력할 때 사용되는 함수가 동일하다).

기존 2022 ~ 2023년 테스트 결과와 2021년은 상당히 유사하다[그림13, 16]. 두 결과 모두 1) 1,000~2,000회 학습 상태에서 수익률이 가장 높았고, 2) 4,000~6,000회 학습에서 수익률이 가장 부진했으며, 3) 이후 학습에서 수익률이 일부 개선됐다. 2023년 1월 테스트는 기간이 짧아 신뢰하기 어렵지만, 이 역시 1,000~2,000회 학습에서 가장 좋은 수익률을 보였다.


3개의 테스트 기간에서 유사한 결과를 얻었다는 점에서 다음 결론을 도출할 수 있다. 학습으로 업데이트된 모델이 최근 10거래일 데이터와 현재 자산 비중을 입력받고 출력하는 비중은 임의의(random) 결과가 아닐 가능성이 높다. 즉, 다음 거래일 손익에 대해 설명력을 가질 가능성이 높다. 그리고 1,000~2,000회 학습된 모델은 향후에도 높은 수익을 낼 가능성이 있다.

[그림16] 2021 년(1 년) 수익률 추이



자료: Binance, 한화투자증권 리서치센터

[그림17] 2023 년 1 월(23 일) 수익률 추이



자료: Binance, 한화투자증권 리서치센터



## VI. 결론

이상 기계학습 중 하나인 강화학습을 통해 투자 알고리즘을 구성하고 성과를 살펴보았다. 모델은 최근 10거래일 자산 별 가격 데이터와 현재 자산 비중을 입력받으면 학습된 행동에 따라 다음 거래일을 위해 비중 조정을 제시한다.

국내 주식(ETF) 시장에 현 모델을 적용하기는 어려워보인다. 모델의 성과가 거래 비용(0.2% 설정)을 이기지 못했다. 모델 수익률이 학습 진행에 따라 일정한 방향을 보이지 않았다는 점도 모델 학습이 잘 이루어졌다고 판단하기 어려운 요인이다.

가상화폐 시장에서의 성과는 괄목할 만하다. 전체적인 수익률은 부진했지만, 모델이 여러 테스트 기간에서 유사한 수익률 패턴을 보였다는 것은 결과에 대한 신뢰를 높여준다. 수익률이 좋았던 1,000~2,000회 사이클 학습된 모델은 앞으로도 양호한 결과를 낼 가능성이 높다.

가상화폐(선물) 시장에서 특정 패턴이 관찰된 배경 중 하나로는 회사 손익, 매크로 지표 등에 영향받지 않아 기술적 지표가 유의미했던 것으로 보인다. 0.05%의 낮은 거래 비용도 결과에 긍정적이었다. 모델을 개선한다면 학습률(현재  $1e^{-4}$ )을 낮추어 모델 학습의 안정성을 높이는 방안 등이 유효할 수 있다.

## [ Compliance Notice ]

(공표일: 2024년 1월 29일)

이 자료는 조사분석 담당자가 객관적 사실에 근거해 작성하였으며, 타인의 부당한 압력이나 간섭없이 본인의 의견을 정확하게 반영했습니다. 본인은 이 자료에서 다룬 종목과 관련해 공표일 현재 관련 법규상 알려야 할 재산적 이해관계가 없습니다. 본인은 이 자료를 기관투자자 또는 제 3자에게 사전에 제공한 사실이 없습니다. (권병재)

저희 회사는 공표일 현재 이 자료에서 다룬 종목의 발행주식을 1% 이상 보유하고 있지 않습니다.

이 자료는 투자자의 증권투자를 돕기 위해 당사 고객에 한하여 배포되는 자료로서 저작권이 당사에 있으며 불법 복제 및 배포를 금합니다. 이 자료에 수록된 내용은 당사 리서치센터가 신뢰할 만한 자료나 정보출처로부터 얻은 것이지만, 당사는 그 정확성이나 완전성을 보장할 수 없습니다. 따라서 이 자료는 어떠한 경우에도 고객의 증권투자 결과와 관련된 법적 책임소재에 대한 증빙으로 사용될 수 없습니다.